


뇌파 기반 사용자 친화

음악 작곡 알고리즘 구현





CONTENTS

01 과제 선정 배경

- 선행 연구 과제
- 과제 목표
- 전체적인 개발 과정

02 데이터 분석

- 데이터 셋
- 뇌파 데이터 전처리
- 감정 분석 feature 추출

03 음악 작곡 및 GUI

- 음악 작곡 알고리즘
- GUI

04 부록

- 블록도
- 참고문헌
- 구성원 역할

데이터 분석 캡스톤 디자인

과제 선정 배경

선행 연구 과제
과제 목표
전체적인 개발 과정

데이터 분석

음악 작곡 및 GUI

부록

- 1934년 : 뇌파의 알파(Alpha)파의 진폭이나 뇌파 신호의 단순하고 직접적인 특징을 통해 소리를 만들 [1]
- 1997년 : 디지털 필터링 및 뇌파 데이터 분석을 통해 새로운 음악 생성 규칙을 만들 [2]
- 2021년 : 스트레스를 치료하기 위한 목적으로 스트레스를 유발하는 뇌파 데이터를 이용해 음악을 만들 [3]



- 현재 자신의 스트레스 상태를 수치화 하여 표현
- 8개의 채널에서 뇌파 수집
- 수집된 뇌파의 알파와 베타파를 이용해 음악 작곡 알고리즘 구현
- 음악 프로그램을 이용해 Subject의 스트레스 상태를 음악으로 표현



스트레스 완화를 목적으로 뇌파를 이용해 음악을 만드는 방법에 대한 의구심.
심리적 안정성이 목표라면 자신이 선호하는 노래를 듣는 것이 오히려 좋은 방법이라 생각.


● 개발 목적 : 뇌파를 통해 사용자 친화적인 음악을 생성, 사용자의 감정을 잘 표현해주는 음악을 생성

→ 사용자는 나를 잘 표현해주는 진정한 나만의 음악을 갖게 될 수 있음.

→ 긍정적 혹은 부정적인 감정을 통해 만들어진 음악으로 인간 내면을 한층 더 깊게 이해할 수 있음.

→ 본인이 선호하는 악기를 선택해 사용자 내면의 익숙하지 않은 감정에 더 쉽게 다가갈 수 있음.

개발 목표



알고리즘 모델 개발



사용자 친화 음악

개발 과정




0. What is EEG?

- EEG (Electroencephalogram)은 뇌의 전기적인 활동을 머리 표면에 부착한 전극에 의해 측정된 전기 신호.
- 델타(0.2Hz ~ 4Hz), 세타(4Hz ~ 8Hz), 알파(8Hz ~ 13Hz), 베타(13Hz ~ 30Hz), 감마(30Hz ~ 45Hz)파로 구분.

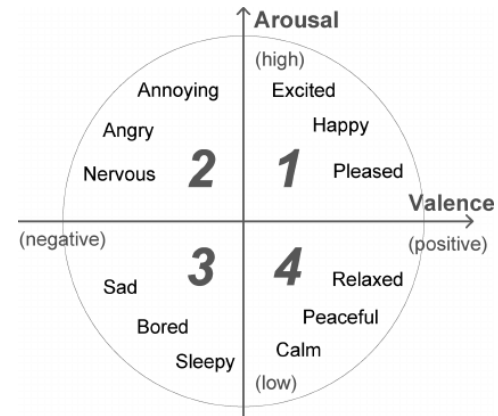


1. DEAP Dataset (Dataset for Emotion Analysis using eeg, Physiological and video signal) [4]

- 32명의 참가자 → 총 40개의 1분 길이의 영상을 3초 정도의 준비시간을 가지고 시청
- 영상 시청 후, 자신이 느낀 감정에 대해 각각의 Label 별로 수치를 결정



32 Channel




Arousal and Valence

→ Arousal: 감정의 격함의 정도
Valence: 감정의 긍부정 정도

- Sampling rate를 128Hz로 하여 32개 Channel에서 나오는 뇌파 측정
- 따라서 총 $32 \times 40 = 1,280$ 개의 csv 파일이 존재하며, 각 csv파일은 $32 \times (63 \times 128)$ 의 shape을 가짐

2. Preprocessing

- 첫 3초는 감정 분석에 중요하지 않을 것이라 판단하여 제거
- 감정의 변화가 확실히 나타날 것으로 예상되는 기준, 3과 7을 기준으로 총 4가지 그룹으로 Grouping
- Arousal/Valence 각각에 대해 7이상이면 1, 3이하이면 0으로 Labeling



3. Feature Extraction

- 감정 분석에 주로 사용 되는 12개의 Channel 선정
→ 긍정적인 감정은 주로 좌측 전두엽, 부정적인 감정은 우측 전두엽과 관련이 있어 pair 형태로 선택 [5]
- 뇌파 분석에 주로 사용 되는 feature 조사 및 추출
→ Time domain, Frequency domain, Time-Frequency domain



Time-domain Feature

- Statistical feature: Mean, Standard deviation, Kurtosis, Skewness
- Hjorth parameters (Mobility, Complexity) [6]
- Fractal Dimension (Higuchi, Petrosian) [7]
- Detrended Fluctuation Analysis [7]
- Hurst Exponent



Frequency-domain Feature

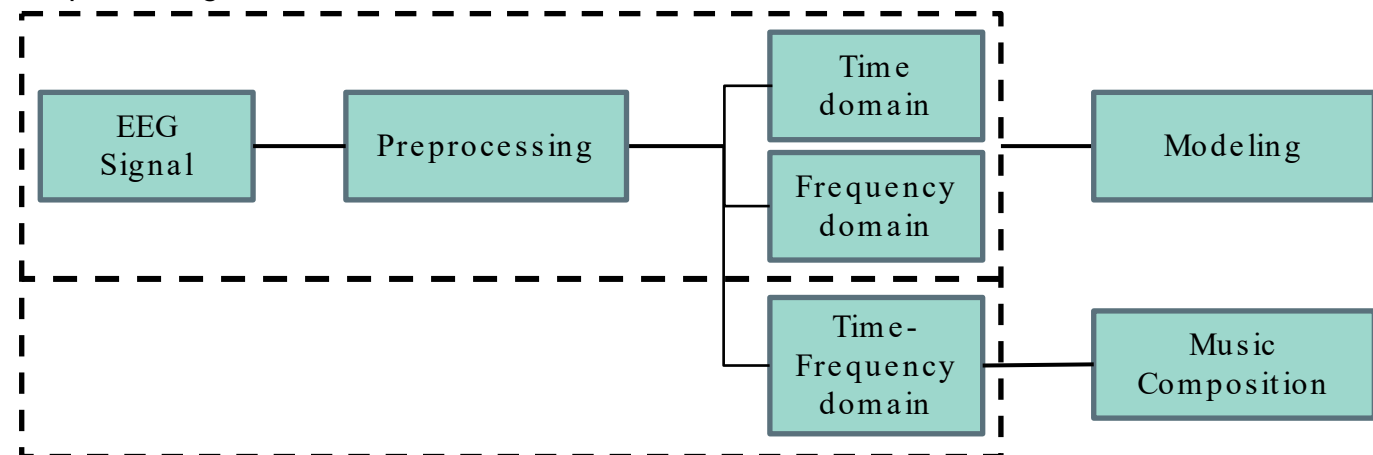
- Power Spectral Density [6]
- Maximum Power Spectral Frequency [6]
- Root Mean Square



Time-frequency-domain Feature

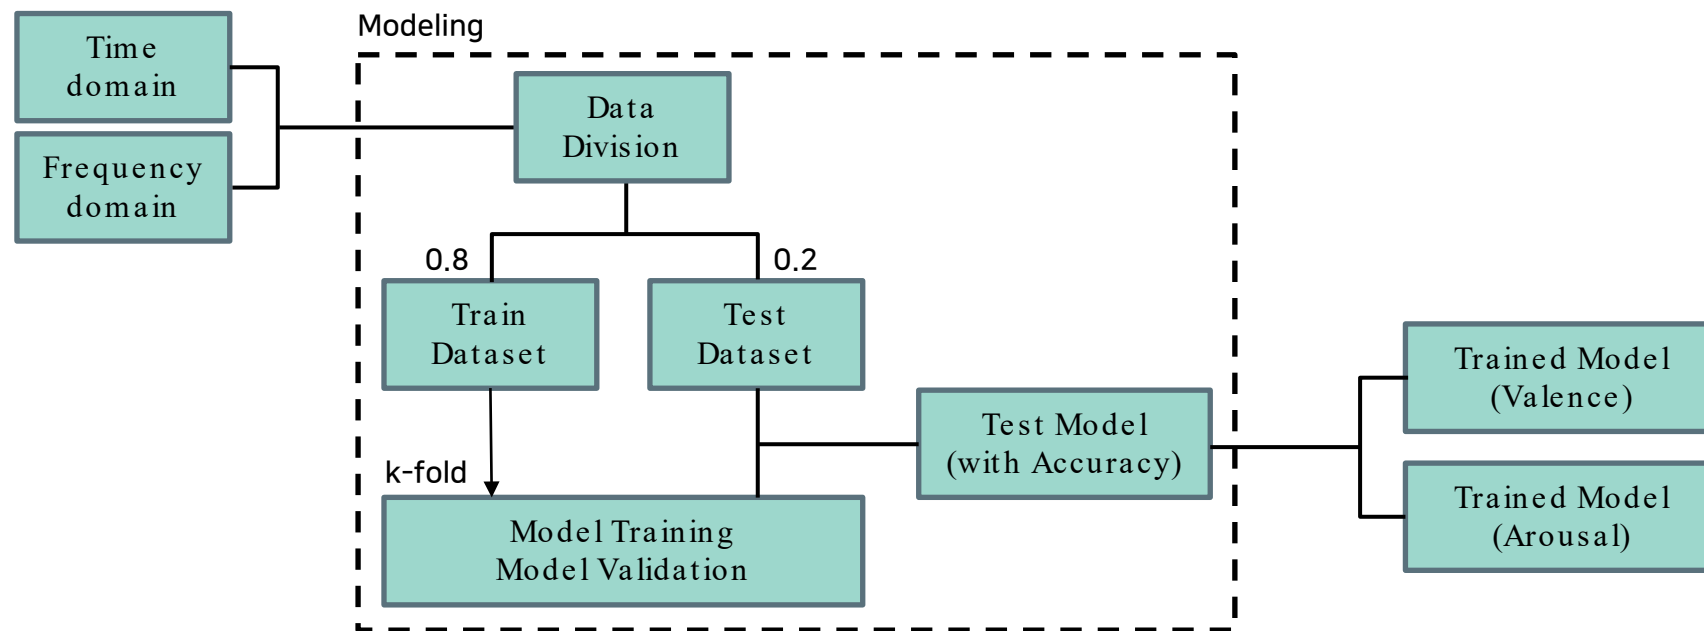
- STFT (Short-Time Fourier Transform)

Preprocessing and Feature extraction



4. Modeling: 다양한 기계학습 모델을 통해 데이터를 잘 분류하는 model selection


→ Arousal/Valence 마다 High/Low를 분류하는 이진 분류 모델 생성




4. Modeling (continued)

→ 가장 높은 성능을 보인 ExtraTreeClassifier, RandomForestClassifier, LGBMClassifier, 3개의 모델을 ensemble

	ETC	RFC	LGBMC	Ensemble
Arousal	0.7687	0.7522	0.7687	0.8134
Valence	0.8000	0.7507	0.7418	0.8030



Arousal Model에 대한 ROC Curve



Valence Model에 대한 ROC Curve


→ 최종적으로 Arousal/Valence 모델 모두 약 80%의 정확도를 보이며 분류

5. Music Composition Algorithm with Pretty-Midi

: 뇌파의 요소와 감정을 나타내는 음악적인 요소들을 Mapping 하여 악보로 만드는 작곡 알고리즘 개발

1. 훈련된 모델을 통해 예측한 Valence를 통해 Major/Minor 결정


→ High = Positive = Major, Low = Negative = Minor



2. 훈련된 모델을 통해 예측한 Arousal를 통해 Tempo 결정.

→ 12개의 Channel에서 예측된 Label, High와 Low의 비율을 이용해 Tempo 결정


→ High = Excited = Fast Tempo, Low = Relax = Slow Tempo



5. Music Composition Algorithm with Pretty-Midi (Continued)

3-1. Maximum Power Spectral Frequency (MPSF)로 Key Chord 결정

→ 피아노의 기본 오른손 주파수 대역대로 Scaling 하였을 때, 가장 가까운 Chord를 Key Chord와 Scale로 결정



3-2. Time-Frequency domain으로 표현되는 STFT를 이용해 Melody 결정

→ 1초 단위의 window로 분할하여, 각 구간 별 최댓값을 가지는 주파수를 3번처럼 Scaling하여 앞서 Key Chord의 스케일에 가장 가까운 음을 친다.

→ Melody 간격이 너무 넓은 경우, 기존 박자보다 더 작은 박자로 interpolation

3-3. 왼손의 경우, 오른손에서 Octave를 2단계 내린 1도 화음을 치도록 함.


5. Music Composition Algorithm with Pretty-Midi (Continued)

4. 강세에 중요한 영향을 미치므로 Arousal 모델에서 가장 중요한 feature를 이용해 Volume 결정

- Scikit-learn을 이용해 앙상블한 각각의 모델의 Importance 계산한 후, min-max scaling하여 Normalization
- 각각의 feature importance에 가중치 1을 곱한 뒤, 합하여 분류기에서 가장 중요하게 영향을 미치는 feature 선택

	Feature	Feature Importance
3	kurtosis	[[2.9779019137953577]]
2	skewness	[[2.783670803167042]]
7	dfa	[[2.765039158224954]]
8	hfd	[[2.571810749063486]]
0	mean	[[2.5349044532388083]]
6	hurst	[[2.532470387172031]]
9	pfd	[[2.4902631665923187]]
5	hjorth_com	[[2.395861001844218]]
4	hjorth_mob	[[2.1717170309740057]]
10	MAX_PSD	[[2.1370603121437663]]
1	std	[[1.9866782466759254]]
11	MAX_freq	[[0.0]]

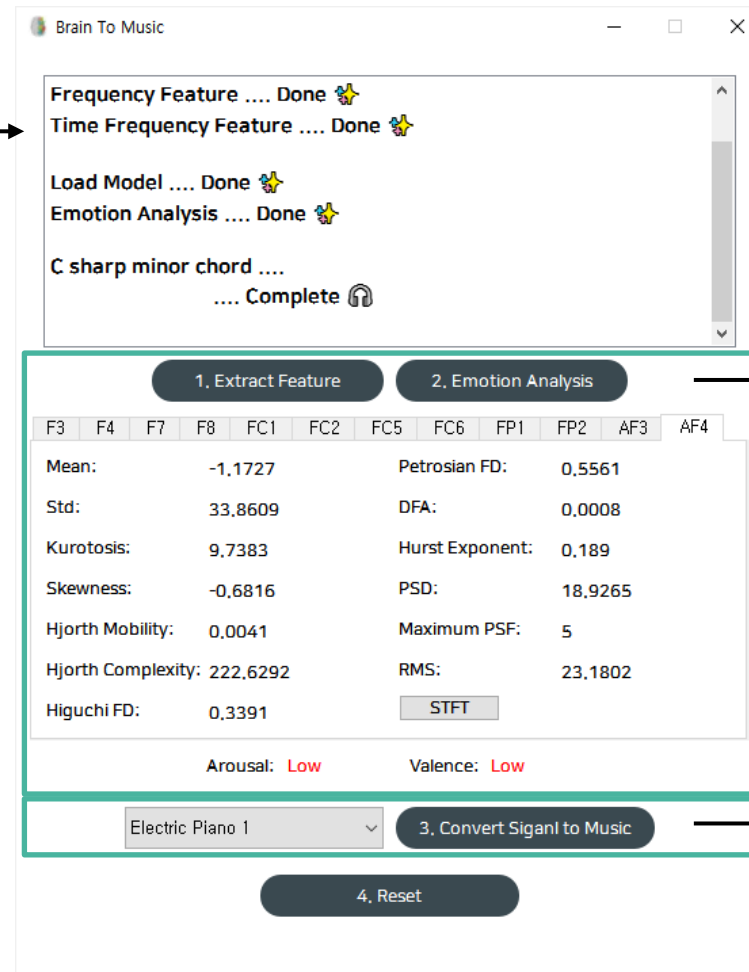
Arousal Feature Importance



- EEG Signal을 10초 간격으로, 1초씩 겹쳐 kurtosis 측정
- 측정한 결과가 High kurtosis KDE에서 발견될 확률이 높으면 +1, Low kurtosis KDE에서 발견될 확률이 높으면 -1

6. GUI (Graphic User Interface)

EEG File Drag and Drop



Feature Extraction and Emotion Analysis

Convert signal to music and save MIDI File

High Arousal
High Valence



Low Arousal
Low Valence



Block Diagram

과제 선정 배경


프로젝트 진행과정

향후 연구 진행 방향

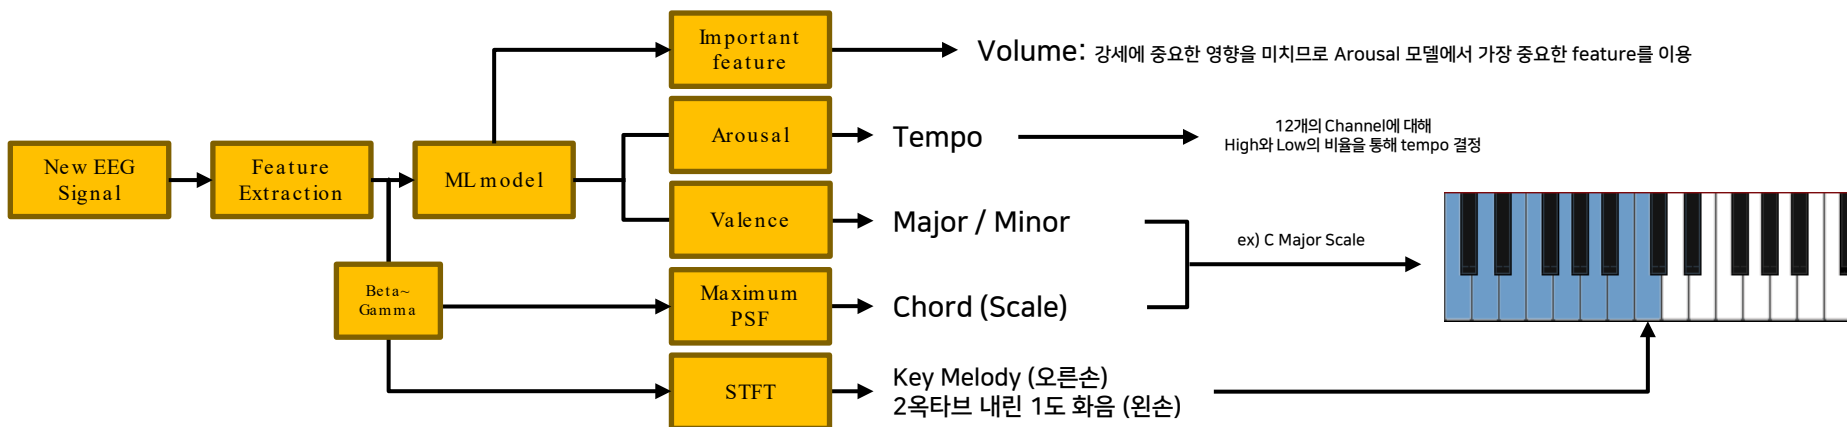
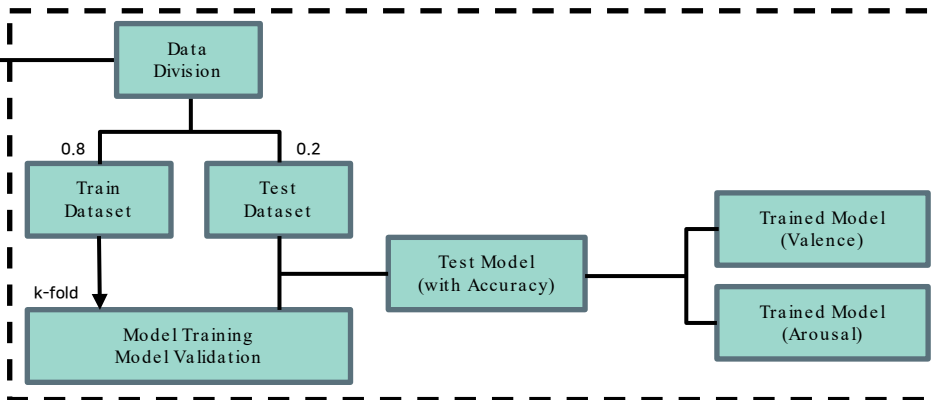
부록

블록도
참고문헌
IDEA-m

Preprocessing and Feature extraction



Modeling



Time Domain Feature

1. Hjorth parameters (mobility, activity, complexity)

- Activity: Signal의 Variance이자, 신호의 Total Power (Frequency domain에서 power spectrum의 모양(surface))
- Mobility: Signal의 Variance를 시간으로 미분한 값의 분산이 비율의 제곱근으로, power spectrum의 표준 편차에 비례함.
- Complexity: Signal Bandwidth의 추정치를 제공하고, 순수 사인파의 신호와의 유사도를 나타냄.

2. Detrended Fluctuation Analysis

- Signal의 통계적인 self-affinity를 결정하는 방법 → Long-memory process인 것처럼 보이는 time series의 분석에 유용
- 기본적으로 비정상 계열의 장거리 상관관계를 조사하기 위한 방법으로 단거리 상관 동작을 조사하는데도 사용 가능

3. Fractal Dimension

- 자기 유사성(self-similarity)와 순환성(recursiveness)를 가지고 공간에 패턴을 얼마나 조밀하게 채우는지를 나타내는 비율
- Higuchi Fractal Dimension (HFD): 프랙탈 차원 계산 중 오차율이 적은 알고리즘
- Petrosian Fractal Dimension (PFD): 프랙탈 차원 계산 고속화 알고리즘

4. Hurst Exponent: 추세(Trend)의 지속성을 측정

- Hurst Exponent < 0.5 : 원래 자리로 되돌아 가려는 속성이 강함
- Hurst Exponent > 0.5 : 추세를 지속시키려는 속성이 강함




Frequency Domain Feature

1. Periodogram Method: 푸리에 변환을 이용하는 표준 방식으로 신호의 Spectral density 추정
→ 낮은 SNR의 정현파에 적용될 때 불리하므로 Welch 방법을 통해 완화
2. Welch Method: 표준 Periodogram과 중첩 세그먼트를 사용하는 Bartlett 방법의 개선 버전
→ 데이터를 중첩된 세그먼트로 나누고, 각 세그먼트에 대해 Periodogram을 계산하고 평균화 하여 Power Spectral Density 및 Power Spectrum의 추정치 계산
3. Power Spectral Density(PSD): Frequency resolution에 따라 진폭이 다르게 보이는 현상을 해결하기 위해 진폭을 정규화 한 것
4. Frequency resolution에 비의존적이라 서로 다른 개수의 데이터를 가지는 신호를 비교하기에 용이.
 - Maximum Power Spectral Density: PSD의 최대값의 제공근
 - Maximum Power Spectral Frequency: PSD의 최대값을 가지는 주파수
 - Root Mean Square: Power Spectrum의 최대값의 제공근

Time-Frequency Domain Feature

1. STFT (Short-time Fourier Transform)
 - 신호를 특정 간격으로 잘라내 Fourier Transform 한 것.
 - 시간에 따른 주파수 변화를 오른쪽과 같은 Spectrogram을 통해 시각화 할 수 있음



참고 문헌

- [1] M. Rajya Lakshmi, Dr. T. V. Prasad, Dr. V. Chandra Prakash, "Survey on EEG Signal Processing Methods", International Journal of Advanced Research in Computer Science and Software Engineering, vol.4, pp. 84-91, 2014.
- [2] Damodar Reddy Edla, Kunal Mangalorekar, et al., "Classification of EEG data for human mental state analysis using Random Forest Classifier", Procedia Computer Science, vol. 132, pp. 1523-1532, 2018.
- [3] Soheyl Noachtar, Jan Rémi, "The role of EEG in epilepsy: A critical review", Epilepsy& Behavior, vol. 15, pp. 22-33, 2009.
- [4] G. Adler, S. Brassen, A. Jajcevic, "EEG coherence in Alzheimer's dementia", Journal of Neural Transmission, pp.1051-1058, 2002.
- [5] E. Adrian and B. Matthews, "The Berger rhythms: potential changes from the occipital lobes in man," Brain, vol. 57, pp. 355-385, 1934.
- [6] D. Rosenboom, "Extended Musical Interface with the Human Nervous System", International Society for the Arts, Sciences and Technology, San Francisco, Calif, USA, 1997.
- [7] T.S. Kim, Y.J. Seo, J.S. Lee, S.E. Chae and Jinung An, "Brain to Music: Musical Representation from Stress-Induced EEG," 2021 9th international winter conference on Brain-Computer Interface, 2021.
- [8] S. Koelstra, C. Muehl, M. Soleymani, J.-S. Lee, A. Yazdani, T. Ebrahimi, T. Pun, A. Nijholt, I. Patras, "DEAP: A Database for Emotion Analysis using Physiological Signals", IEEE Transactions on Affective Computing, Special Issue on Naturalistic Affect Resources for System Building and Evaluation, in press.
- [9] Mi Li, et al., Emotion recognition from multichannel EEG signals using K-nearest neighbor classification, in: Technology and health care, 2018.07
- [10] Zaynab Mohammadi, et al., Wavelet-based emotion recognition system using EEG signal, in: Neural Computing and Applications (NEURAL COMPUT APPL), 2017.08
- [11] Xiang Li, et al., "Exploring EEG features in Cross-Subject Emotion Recognition," Frontiers in Neurosciences, 2018.
- [12] Rab Nawaz, et al. Comparison of different feature extraction methods for EEG based emotion recognition, in: Biocybernetics and Biomedical Engineering, 2020.

Github

<https://github.com/IDEA-m/Brain-to-Music>

IDEA-m



산업경영공학과 김다예



소프트웨어융합학과 차준영



소프트웨어융합학과 한주혁



감사합니다

